Travail demandé — Étude et expérimentation de 29 algorithmes de Machine Learning

Public : S7 — **Organisation :** Individuel — **Support :** ce notebook Google Colab.

Objectif général

À partir des **29 algorithmes présentés dans ce notebook**, compléter la partie théorique et enrichir les expériences pratiques afin de comprendre **le principe de chaque algorithme, son fonctionnement, les contextes dans lesquels il est pertinent et ses performances sur des données réelles**.

> **Important :** les cellules Python déjà présentes constituent des **exemples de démonstration**. Plusieurs utilisent des **données synthétiques** : elles ne suffisent donc pas à satisfaire l'exigence finale de tests sur données réelles. Vous devez conserver les exemples, ajouter vos propres explications et réaliser ensuite les expérimentations demandées.

Partie A — Questions à traiter pour **chaque algorithme** (1 à 29)

Q1. Présentation de l'algorithme. Rédigez une présentation synthétique (8 à 12 lignes) précisant :

- son **nom** en français et en anglais, sa **famille** (régression, classification, clustering, réduction de dimension, détection d'anomalies ou renforcement) et l'objectif poursuivi ;
- son **intuition** et les étapes principales : données en entrée → apprentissage / calcul → prédiction, regroupement ou décision en sortie ;
- **une formule ou un critère mathématique essentiel** lorsque cela est pertinent, en **définissant tous les symboles** et en distinguant paramètres et hyperparamètres ;
- deux avantages et deux limites.

Q2. Schéma explicatif. Créez **au moins un schéma original, lisible et légendé** montrant son principe (diagramme de flux, arbre, frontière de décision, nuage de points, mise à jour de centroïdes, agrégation d'arbres, boucle agent–environnement, etc.). Insérez-le dans le notebook, avec **un commentaire expliquant comment le lire**. Vous pouvez utiliser Matplotlib ou intégrer une image créée par vos soins. Indiquez la source si vous adaptez une figure publiée.

Q3. Contexte d'utilisation. Identifiez :

- **deux cas d'usage concrets**, dont au moins un en **finance, gestion, commerce international, marketing ou logistique** ;
- la nature des données et les prérequis techniques ;
- un cas dans lequel l'algorithme serait **peu approprié**, en expliquant pourquoi ;
- les métriques adaptées pour juger ses résultats.

Q4. Commentaire du code. Exécutez le code fourni, expliquez en quelques lignes les entrées, les hyperparamètres, la sortie obtenue et **ce que la sortie permet — ou ne permet pas — de conclure**. N'inventez aucune métrique ni aucun résultat.

À insérer sous chaque titre d'algorithme : quatre sous-sections Markdown `Présentation`, `Schéma explicatif`, `Contextes d'utilisation`, `Analyse de l'expérience Python`.

Partie B — Expérimentation finale sur des **données réelles**

Q5. Choix et traçabilité des données. Sélectionnez des jeux de données **publics et réels**, adaptés aux différentes familles ; notez pour chacun **nom, organisme source, URL exacte, licence/conditions d'accès, taille, colonnes, cible éventuelle et date de consultation**. Un même dataset peut servir à plusieurs algorithmes **compatibles**, mais pas à des tâches artificiellement différentes. **Ne pas utiliser de données inventées ou simulées pour cette partie.**

Sources possibles (vérifiez l'accès effectif et la correspondance avec la tâche) :

- UCI Machine Learning Repository — ex. Default of Credit Card Clients, Online Retail ;
- OpenML ;
- Banque mondiale, indicateurs ;
- UN Comtrade — données de commerce international, extraction à documenter.

Q6. Préparation. Chargez les données dans Pandas ; expliquez les valeurs manquantes, types, doublons, valeurs extrêmes et éventuel déséquilibre de classes. Évitez la fuite d'information en ajustant tout prétraitement appris **sur l'entraînement uniquement**.

Q7. Expériences. Testez **chaque algorithme applicable sur un jeu de données réel approprié**. Pour les algorithmes supervisés, séparez entraînement, validation et test ; pour les séries temporelles, utilisez une **validation chronologique**. Pour les méthodes non supervisées, expliquez les critères internes et, si des étiquettes réelles existent, utilisez-les seulement pour une évaluation externe. Pour les bandits, Q-learning, SARSA et DQN, utilisez des **environnements publics Gymnasium** plutôt qu'un CSV fixe : les trajectoires observées sont générées par l'interaction ; distinguez cette simulation d'un dataset réel. Le DQN du notebook est **conceptuel** : une expérience DQN complète est facultative et doit être signalée comme telle.

Q8. Comparaison et interprétation. Pour chaque famille, comparez au moins une **méthode de référence** et une méthode avancée :

- régression : MAE, RMSE, R^2 ;
- classification : F1, rappel, précision, ROC-AUC ou PR-AUC selon la tâche ;
- clustering : silhouette, stabilité et interprétation ;
- réduction de dimension : variance expliquée (ACP), conservation des voisinages (t-SNE/UMAP) ;
- anomalies : qualité des alertes, et précision/rappel uniquement si des étiquettes fiables sont disponibles ;
- renforcement : récompense cumulée, taux de réussite et variation entre graines.

Présentez vos résultats dans des **tableaux comparatifs** et des **figures légendées**, puis discutez performance, coût de calcul, interprétabilité et limites. Fixez les graines (`random_state=42` lorsque possible), donnez les versions des bibliothèques et évitez de régler les paramètres sur le test final.

Partie C — Livrables et critères de réussite

À remettre par chaque binôme :

1. Ce notebook `.ipynb` complété avec **les réponses Q1–Q4 pour les 29 algorithmes**, des schémas et les sorties d'exécution ;
2. Les expériences supplémentaires **Q5–Q8**, avec jeux de données publics cités et comparaisons reproductibles (ou justification claire des incompatibilités / limites pour les méthodes de renforcement) ;
3. Un **rapport de synthèse** (5 à 8 pages) présentant les principales conclusions, le tableau comparatif final et les références ;
4. Une **courte démonstration orale** où les deux membres expliquent leurs contributions.

Barème indicatif /20 : présentation et exactitude scientifique (5), schémas originaux et pédagogiques (4), pertinence des contextes d'utilisation (3), rigueur des essais réels et des métriques (5), reproductibilité et qualité de restitution (3).

Points de vigilance : ne pas recopier les définitions sans les comprendre ; ne pas inventer de résultats ; ne pas appeler « données réelles » les jeux synthétiques du notebook ; ne pas évaluer des algorithmes incompatibles sur la même cible ; citer vos sources et documenter l'éventuel usage d'une IA.

Support d'expérimentation — exemples Python existants

Les 29 exemples qui suivent sont conservés. **Insérez vos réponses sous le titre de chaque algorithme**, puis ajoutez une partie finale de tests sur données réelles à la suite du notebook.